Projet d'étude

4 ModIA
UFs Analyse de données & Eléments de modélisation statistique
Intervenantes : Cathy Maugis-Rabusseau et Béatrice Laurent-Bonneau

2026-2027

Organisation du projet et documents à rendre

- Le projet sera réalisé par groupe de 4 étudiant-e-s. La constitution des groupes sera donnée lors de la première séance.
- 6 séances de 2h30 sont dédiées dans votre emploi du temps au travail du projet. L'une de nous sera présente lors de chacune de ces séances pour répondre à vos questions.
- Livrables : vous devrez rendre (en déposant sous Moodle) au plus tard le **vendredi 5 février 2027 minuit** les 2 documents suivants :
  1. un fichier quarto (*nom1-nom2-nom3-nom4-Rapport.qmd*) contenant les codes R et générant le rapport au format pdf.
  2. un rapport au format .pdf (*nom1-nom2-nom3-nom4-Rapport.pdf*) généré par la compilation du fichier .qmd précédent.
     Attention : le rapport est limité à 25 pages, figures incluses.
- Un dossier "ModeleRapport", disponible sur Moodle, vous donne un exemple avec des consignes pour la rédaction de votre rapport. Il est important d'en prendre connaissance dès la première séance !

Usage de l'IA : L'IA générative ne peut être éventuellement utilisée que pour améliorer les graphiques en ggplot que vous avez préalablement effectué sans l'utiliser (et non pour réaliser le travail à votre place). La rédaction de votre projet ne doit pas utiliser l'IA, elle doit être personnelle.

- Formation et déficit cognitif : Vous êtes ici pour vous former, pas pour produire. L'IAg accélère la production mais dégrade la formation : en laissant l'IAg réfléchir et produire à votre place, vous n'exercez pas vos propres capacités.
- Satisfaction : Réussir à faire par soi-même, sans IAg, procure un sentiment de confiance dans ses propres compétences.
- Réciprocité : votre travail sera corrigé par vos enseignantes, et non par une IAg. Lire de l'IAg ou se rendre compte que vous l'avez utilisé énervera le correcteur et sera un manque de respect envers son travail. En cas d'utilisation abusive de l'IAg, le correcteur pourra donc mettre une note en dessous de 10 au travail.

Jeu de données étudié

Les données sont issues du site du concours KAGGLE ; il s'agit du jeu de données synthétiques "Cardiovascular Disease Risk Prediction Dataset". Ce jeu de données comporte des dossiers médicaux synthétiques de patients spécialement conçus pour prédire le risque de maladie cardiovasculaire. Bien que synthétiques, les données sont générées à l'aide d'heuristiques médicales afin de garantir des corrélations réalistes entre les variables, telles que la relation entre l'âge, l'IMC et la pression artérielle. Le jeu de données comporte 19 variables pour 15000 patients.

Nous avons extrait de ce jeu de données un échantillon de 2099 observations des 15 variables suivantes :

- `Age` : Age du patient
- `Gender` : Genre du patient (qualitative à deux modalités)
- `Height_cm` : Taille du patient en centimètres
- `Weight_kg` : Poids du patient en kilogrammes
- `BMI` : Indice de masse corporelle (IMC), calculé à partir de la taille et du poids en kg/m2
- `Systolic_BP` : Pression artérielle systolique (mmHg)
- `Diastolic_BP` : Pression artérielle diastolique (mmHg)
- `Cholesterol_Total` : Cholestérol sérique total (mg/dL)
- `Cholesterol_LDL` : Lipoprotéines de basse densité / « mauvais » cholestérol (mg/dL)
- `Cholesterol_HDL` : Lipoprotéines de haute densité / « bon » cholestérol (mg/dL)
- `Smoking_Status` : Statut tabagique (qualitative à deux modalités)
- `Alcohol_Consumption` : niveau de consommation d'alcool (qualitative à trois modalités)
- `Physical_Activity_Level` : Niveau d'activité physique (qualitative à quatre modalités)
- `Family_History` : Antécédents familiaux de maladie cardiaque (qualitative à deux modalités).
- `Heart_Disease_Risk` : Risque d'accident cardiaque (qualitative à deux modalités) 0 : risque faible, 1 : risque élevé.

C'est sur ce jeu de données que vous allez travailler.

Questions à aborder

Dans votre rapport final, vous devez avoir abordé par une/des méthodes adaptées les questions suivantes. Il est indiqué par [■] les questions qui correspondent à des notions abordées durant la période de septembre et novembre, par [▲] pour la période de janvier. Il est recommandé de suivre l'ordre des questions pour la rédaction de votre rapport.

1. Analyse descriptive du jeu de données [■]
   - Faites quelques statistiques descriptives du jeu de données.
     Vous adapterez vos choix à la nature des variables et étudirez les corrélations / liaisons entre les différentes variables
   - Visualisez les individus dans un espace de faible dimension à partir des variables quantitatives. Interprétez.
   - Visualisez les individus dans un espace de faible dimension à partir des variables qualitatives. Interprétez.
2. Tests d'hypothèses [▲]
   - Utilisez un test approprié afin de déterminer si le taux de `Cholesterol_LDL` dépend du genre. Dépend-il du fait de fumer ou non ?
   - Testez la dépendance entre la variable `Heart_Disease_Risk` et chacune des variables qualitatives du jeu de données.
   - La variable `Cholesterol_LDL` suit-elle une loi normale ?

3. Clustering des individus
   Dans cette partie, on ne considère que les variables `Systolic_BP`, `Diastolic_BP`, `Cholesterol_Total`, `Cholesterol_LDL` *et* `Cholesterol_HDL`. *Vous prendrez soin de justifier vos choix et mettrez en compétition plusieurs méthodes pour le choix du nombre de classes. Vous retiendrez un clustering final pour chacune des questions suivantes.*
   - Obtenez un clustering des individus à partir de ces 5 variables par une méthode hiérarchique [■]
   - Obtenez un clustering des individus à partir de ces 5 variables par une méthode de type Kmeans [■]
   - Obtenez un clustering des individus à partir de ces 5 variables par une modélisation par mélanges gaussiens [▲]
   - Comparez les clusterings obtenus à l'aide d'indicateurs et par une méthode factorielle. Interprétez ces clusterings à l'aide des variables du jeu de données.
4. Etude de la variable `Cholesterol_LDL` (mauvais cholestérol) [■]
   - Modélisez la variable `Cholesterol_LDL` en fonction des autres variables quantitatives. Visualisez les résidus et commentez. Peut-on simplifier le modèle ? Reprenez ces analyses en supposant que l'on ne dispose pas de la valeur de `Cholesterol_Total` et comparez les résultats obtenus.
   - Modélisez la variable `Cholesterol_LDL` en fonction des deux variables qualitatives : `Gender` et `Physical_Activity_Level`. Peut-on simplifier le modèle ?
   - Modélisez la variable `Cholesterol_LDL` en fonction de toutes les variables explicatives (sauf la variable `Heart_Disease_Risk`) et utilisez une méthode de sélection de modèles que vous connaissez pour simplifier le modèle. Visualisez les résidus et commentez. Reprenez ces analyses en supposant que l'on ne dispose pas de la valeur de `Cholesterol_Total` et comparez les résultats obtenus.
5. Etude de la variable `Heart_Disease_Risk` [■]
   - Modélisez la variable `Heart_Disease_Risk` en fonction des autres variables.
   - Utilisez une procédure de sélection de modèles pour simplifier le modèle précédent. Analysez les résultats obtenus avec ce modèle.

Evaluation du projet

Pour chaque UF, la note de projet compte pour un tiers de la note finale de l'UF. Elle sera issue de l'évaluation des critères suivants :

Critère	**UF EMS**	**UF AD**
Utilisation pertinente des méthodes d'exploration de données		x
Utilisation pertinente de méthodes de clustering adaptées à la question traitée		x
Utilisation pertinente de l'analyse discriminante linéaire		x
Choix des modélisations ML et MLG adaptées à la question traitée	x	
Ecriture mathématique des modèles considérés	x	
Choix des procédures de tests adaptées à la question traitée	x	
Utilisation de méthodes de sélection de variables	x	
Aller-retour exploration $\leftrightarrow$ modélisation	x	x
Analyse ($\neq$ lecture !) des résultats obtenus	x	x
Choix et rendu des graphiques illustratifs	x	x
Rédaction d'un document en quarto		x
Programmation en R	x	x
Rédaction générale du document	x	x
Bonus pour des choix originaux adaptés	x	x